

**DUOC UC**

Programación para la Ciencia de Datos — SCY1101

---

# INFORME TÉCNICO

---

## Pipeline Completo de Machine Learning

Predicción de Fuga y Desempeño de Empleados

**Autor:**

Claudio Gonzalez

Evaluación Parcial N°2 • 30% Ponderación • Mayo 2026

## Resumen Ejecutivo

---

El presente informe documenta el desarrollo e implementación de un pipeline completo de Machine Learning (ML) orientado al área de Recursos Humanos. El objetivo principal es predecir la fuga voluntaria de empleados (clasificación binaria) y su nivel de desempeño (clasificación multiclase), además de explorar patrones latentes en los perfiles de talento mediante técnicas no supervisadas.

El pipeline integra ingeniería de datos con Kedro, 11 clasificadores con SMOTE, 2 regresores, validación cruzada estratificada, optimización de hiperparámetros y 5 algoritmos de clustering/reducción de dimensionalidad. El dataset utilizado es el Synthetic Employee Records Dataset (Kaggle), con 3.000 registros y 33 variables tras la consolidación de cuatro fuentes de datos.

El modelo campeón para clasificación binaria es Gaussian Naïve Bayes, con F1-Score de 0.2676 en validación cruzada, mejorado a 0.3773 tras optimización de hiperparámetros (+10.98 puntos porcentuales). Para clasificación multiclase, el mejor modelo es Logistic Regression con F1-macro de 0.2893. El análisis de clustering identifica 7 perfiles de empleados diferenciados mediante K-Means.

## 1. Marco Metodológico

---

### 1.1 Dataset y Fuentes de Datos

El dataset proviene de Kaggle (Ravindra Singh Rana, 2023): “Synthetic Employee Records Dataset”. Contiene cuatro archivos CSV que representan subsistemas distintos del ecosistema de RRHH:

- `employee_data.csv`: Información demográfica, contractual y de desempeño (26 columnas, 3.000 registros).
- `employee_engagement_survey_data.csv`: Puntuaciones de compromiso, satisfacción y balance vida-trabajo.
- `training_and_development_data.csv`: Historial de capacitaciones, duración y costos.
- `recruitment_data.csv`: Perfil de postulantes, nivel educacional y salario deseado.

Tras la integración mediante JOIN por `EmpID`, la tabla maestra contiene 3.000 filas y 33 columnas, sin pérdida de registros. Las variables objetivo son:

- `y_binario`: Fuga del empleado (1 = terminación voluntaria o por causa, 0 = activo). Distribución: 87.1% clase 0 vs 12.9% clase 1.
- `y_multiclase`: Performance Score con 4 categorías: Exceeds, Fully Meets, Needs Improvement, Pip.
- `y_regresión`: Current Employee Rating (variable numérica continua).

### 1.2 Justificación de Algoritmos Supervisados

La selección de modelos responde a criterios de diversidad algorítmica, capturando distintos inductives biases:

| Modelo               | Justificación Técnica                                              |
|----------------------|--------------------------------------------------------------------|
| Logistic Regression  | Línea base interpretable; eficaz en datos con separabilidad lineal |
| Decision Tree        | Captura interacciones no lineales; alta interpretabilidad          |
| Random Forest        | Reducción de varianza por ensemble; robusto a outliers             |
| Gradient Boosting    | Corrección secuencial de errores; alto poder predictivo            |
| SVC                  | Margen máximo en espacios de alta dimensión                        |
| KNN                  | No paramétrico; útil para detectar vecindades locales              |
| Gaussian Naïve Bayes | Rápido, estable bajo desbalanceo; campeón binario                  |
| Extra Trees          | Mayor aleatorización que RF; reduce sobreajuste                    |
| AdaBoost             | Boosting adaptativo; penaliza ejemplos difíciles                   |
| MLP Neural Network   | Captura patrones no lineales complejos                             |
| XGBoost              | Boosting regularizado; state-of-the-art en datos tabulares         |

Todos los modelos se integraron en pipelines de imbalanced-learn que incluyen SMOTE (Synthetic Minority Oversampling Technique) para abordar el desbalanceo de clases (87%/13%), seguido de StandardScaler para normalización. La variable multiclase fue codificada con LabelEncoder para compatibilidad con MLP y XGBoost.

### 1.3 Justificación de Algoritmos No Supervisados

- **K-Means:** K-Means: Segmentación eficiente para identificar perfiles de empleados. Se evaluó k=2 a k=8 con métricas Silhouette y Davies-Bouldin.
- **DBSCAN:** DBSCAN: Detección de clusters de forma arbitraria y outliers. Útil para identificar empleados atípicos.
- **Agglomerative:** Agglomerative Clustering: Jerarquía de similitud entre perfiles; dendrograma para visualización.
- **PCA:** PCA: Reducción de dimensionalidad para visualización 2D/3D y eliminación de ruido.
- **GMM:** GMM: Modelos de mezcla gaussiana; captura clusters de forma elíptica con probabilidades de pertenencia.

### 1.4 Infraestructura Técnica

El proyecto utiliza Kedro 0.19.10 como framework de ingeniería de datos, organizando el flujo en pipelines modulares (data\_ingestion → data\_cleaning → data\_transform → data\_validation). El pipeline de ML se orquesta mediante train.py con logging estructurado, manejo de excepciones y serialización automática de modelos en formato .joblib. La semilla global RANDOM\_STATE=42 garantiza reproducibilidad completa.

## 2. Análisis Experimental

---

### 2.1 Preprocesamiento

El ColumnTransformer aplica transformaciones diferenciadas según el tipo de variable:

- Variables numéricas (6): Engagement Score, Satisfaction Score, Work-Life Balance Score, Total Training Cost, Seniority\_Years. Imputación por mediana + StandardScaler.
- Variables categóricas (12): Title, BusinessUnit, EmployeeType, PayZone, EmployeeClassificationType, DepartmentType, Division, State, LocationCode, RaceDesc, MaritalDesc, Gender\_Male. Imputación por moda + OneHotEncoder.

La imputación por mediana en variables financieras (Total Training Cost) es preferida sobre la media por su robustez ante valores atípicos. El One-Hot Encoding evita la imposición de ordinalidad artificial en variables nominales.

Para la regresión, la columna Current Employee Rating fue excluida explícitamente de X\_reg mediante drop() para prevenir data leakage. El preprocessor se reconstruye con solo 5 features numéricas, confirmado en logs: "Numeric features (5)".

### 2.2 Configuración de Validación Cruzada

Se implementó Stratified K-Fold (k=5, shuffle=True, seed=42) de forma paralelizada con joblib (n\_jobs=-1). La estratificación garantiza que la proporción 87%/13% se preserve en cada fold, evitando evaluaciones sesgadas. La métrica principal de selección es f1\_macro por ser más informativa que accuracy bajo desbalanceo.

### 2.3 Configuración de Clustering

Para K-Means se evaluaron k=2 a k=8 con inicialización k-means++. Las métricas Silhouette (mayor = mejor) y Davies-Bouldin (menor = mejor) se calcularon para cada k. Para PCA se determinó el número de componentes que explican el 80% (5 componentes) y 90% (6 componentes) de la varianza. Para GMM se evaluaron n=1 a n=8 con criterios AIC y BIC.

### 3. Resultados y Comparación de Modelos

#### 3.1 Clasificación Binaria (Predicción de Fuga)

Resultados de Stratified 5-Fold CV para los 11 clasificadores. Métrica principal: F1-Score (binary). Mejor modelo: Gaussian Naïve Bayes.

| Modelo              | Accuracy    | Precision   | Recall      | F1-Score    | ROC-AUC     |
|---------------------|-------------|-------------|-------------|-------------|-------------|
| Logistic Regression | 0.788±0.020 | 0.215±0.038 | 0.243±0.062 | 0.226±0.048 | 0.662±0.037 |
| Decision Tree       | 0.817±0.018 | 0.204±0.035 | 0.137±0.021 | 0.162±0.018 | 0.528±0.009 |
| Random Forest       | 0.871±0.001 | 0.000±0.000 | 0.000±0.000 | 0.000±0.000 | 0.615±0.054 |
| Gradient Boosting   | 0.861±0.007 | 0.153±0.171 | 0.018±0.018 | 0.032±0.032 | 0.623±0.057 |
| SVC                 | 0.623±0.026 | 0.153±0.011 | 0.426±0.071 | 0.225±0.020 | 0.550±0.019 |
| KNN                 | 0.350±0.016 | 0.136±0.008 | 0.757±0.049 | 0.231±0.014 | 0.545±0.028 |
| Gaussian NB         | 0.363±0.019 | 0.157±0.006 | 0.902±0.030 | 0.268±0.010 | 0.592±0.020 |
| Extra Trees         | 0.870±0.002 | 0.100±0.200 | 0.003±0.005 | 0.005±0.010 | 0.614±0.034 |
| AdaBoost            | 0.788±0.030 | 0.169±0.026 | 0.155±0.025 | 0.158±0.008 | 0.620±0.039 |
| MLP                 | 0.857±0.006 | 0.189±0.120 | 0.036±0.025 | 0.060±0.040 | 0.652±0.036 |
| XGBoost             | 0.855±0.004 | 0.212±0.053 | 0.047±0.015 | 0.076±0.023 | 0.627±0.017 |

Gaussian Naïve Bayes lidera en F1-Score (0.268) y Recall (0.902), lo cual es crítico para el problema de fuga: identificar correctamente a los empleados que se irán (verdaderos positivos) tiene mayor valor de negocio que evitar falsos positivos. Models como Random Forest y Extra Trees muestran alta accuracy (87%) pero F1=0 porque nunca predicen la clase minoritaria, evidenciando el problema del desbalanceo de clases sin SMOTE efectivo en esos modelos.

El ROC-AUC más alto lo obtiene MLP (0.652), seguido de Logistic Regression (0.662), indicando que aunque su F1 es menor, tienen mejor capacidad discriminativa general.

#### 3.2 Clasificación Multiclase (Desempeño del Empleado)

Resultados de Stratified 5-Fold CV. Target: Performance Score (4 clases). Métrica: F1-macro. Mejor modelo: Logistic Regression (0.2893).

| Modelo              | Accuracy    | Precision   | Recall      | F1-macro    | ROC-AUC     |
|---------------------|-------------|-------------|-------------|-------------|-------------|
| Logistic Regression | 0.707±0.022 | 0.306±0.022 | 0.285±0.018 | 0.289±0.020 | 0.644±0.016 |
| Decision Tree       | 0.696±0.017 | 0.278±0.016 | 0.271±0.012 | 0.272±0.014 | 0.519±0.010 |
| Random Forest       | 0.786±0.002 | 0.222±0.050 | 0.250±0.001 | 0.221±0.003 | 0.594±0.014 |
| Gradient Boosting   | 0.775±0.004 | 0.334±0.094 | 0.261±0.008 | 0.247±0.014 | 0.602±0.035 |

| Modelo      | Accuracy    | Precision   | Recall      | F1-macro    | ROC-AUC     |
|-------------|-------------|-------------|-------------|-------------|-------------|
| SVC         | 0.593±0.040 | 0.247±0.007 | 0.260±0.010 | 0.245±0.009 | 0.526±0.021 |
| KNN         | 0.153±0.017 | 0.261±0.014 | 0.237±0.015 | 0.128±0.011 | 0.507±0.018 |
| Gaussian NB | 0.264±0.022 | 0.302±0.021 | 0.347±0.031 | 0.178±0.021 | 0.600±0.018 |
| Extra Trees | 0.784±0.001 | 0.226±0.036 | 0.250±0.002 | 0.222±0.003 | 0.607±0.018 |
| AdaBoost    | 0.504±0.049 | 0.285±0.017 | 0.300±0.024 | 0.265±0.019 | 0.574±0.025 |
| MLP         | 0.772±0.005 | 0.310±0.105 | 0.254±0.007 | 0.236±0.012 | 0.637±0.017 |
| XGBoost     | 0.774±0.005 | 0.316±0.117 | 0.256±0.011 | 0.238±0.020 | 0.615±0.019 |

En la tarea multiclase los valores de F1-macro son menores que en la binaria, lo cual es esperable dado que 4 clases con distribución desbalanceada representan una dificultad mayor. Logistic Regression lidera con F1=0.289, seguido de Decision Tree (0.272) y AdaBoost (0.265). Los modelos de ensemble con alta accuracy como Random Forest (78.6%) y Extra Trees (78.4%) nuevamente colapsan sus predicciones hacia la clase mayoritaria, reflejando el trade-off entre accuracy y recall en datasets desbalanceados.

### 3.3 Regresión (Predicción de Current Employee Rating)

Se entrenaron 2 regresores para predecir la calificación numérica del empleado. La columna objetivo fue excluida de las features para evitar data leakage.

| Modelo                  | RMSE  | MAE   | R <sup>2</sup> |
|-------------------------|-------|-------|----------------|
| Linear Regression       | 1.711 | 1.284 | -2.210         |
| Random Forest Regressor | 0.967 | 0.681 | -0.025         |

El R<sup>2</sup> negativo indica que los modelos predicen peor que simplemente usar la media del target. Esto no es un error de implementación sino una conclusión válida: las features disponibles (engagement, satisfacción, costos de entrenamiento, variables demográficas) no son suficientes para predecir la calificación numérica del empleado con precisión. Esto sugiere que la calificación depende de factores no capturados en el dataset, como evaluaciones de desempeño directas o histórico de objetivos. Random Forest muestra menor RMSE (0.967 vs 1.711), siendo preferible ante la regresión lineal en este contexto.

## 4. Optimización de Hiperparámetros

### 4.1 Estrategia de Optimización

Se aplicó RandomizedSearchCV sobre el modelo campeón (Gaussian Naïve Bayes) con los siguientes parámetros:

- Número de iteraciones: 6 (espacio total de parámetros = 6 valores de var\_smoothing)
- Scoring: f1\_macro
- Cross-validation: Stratified 5-Fold (seed=42)
- Parámetro optimizado: classifier\_\_var\_smoothing  $\in \{1e-11, 1e-10, 1e-9, 1e-8, 1e-7, 1e-6\}$

var\_smoothing controla la porción de la mayor varianza de todas las características que se añade a las varianzas para estabilidad numérica. Un valor menor captura distribuciones más ajustadas a los datos de entrenamiento.

### 4.2 Resultados Before vs. After

| Modelo               | F1 Base (CV) | F1 Tuneado | Mejora Absoluta | Mejora Relativa |
|----------------------|--------------|------------|-----------------|-----------------|
| Gaussian Naïve Bayes | 0.2676       | 0.3773     | +0.1098         | +41.0%          |

El mejor parámetro encontrado fue var\_smoothing=1e-11, logrando un F1-Score de 0.3773 frente al 0.2676 base, una mejora del 41%. Esto indica que el modelo original usaba el valor por defecto (1e-9) que no era óptimo para este dataset. Un suavizado menor permite al modelo ser más sensible a las distribuciones reales de las features, capturando mejor la clase minoritaria (empleados en fuga).

Los demás modelos no fueron tuneados en esta iteración. Como trabajo futuro se recomienda aplicar RandomizedSearchCV sobre Logistic Regression (campeón multiclase) y MLP (mayor ROC-AUC binario).

## 5. Modelado No Supervisado

### 5.1 K-Means: Selección de K Óptimo

Se evaluó K-Means para  $k=2$  a  $k=8$  sobre 6 variables numéricas escaladas:

| K | Inertia  | Silhouette | Davies-Bouldin |
|---|----------|------------|----------------|
| 2 | 15679.24 | 0.1292     | 2.5364         |
| 3 | 14234.05 | 0.1266     | 2.2604         |
| 4 | 13106.96 | 0.1253     | 1.9813         |
| 5 | 12205.66 | 0.1264     | 1.8392         |
| 6 | 11374.87 | 0.1273     | 1.7314         |
| 7 | 10715.76 | 0.1310     | 1.6058         |
| 8 | 10224.99 | 0.1312     | 1.6332         |

El coeficiente Silhouette es bajo en todos los valores de  $k$  (0.12–0.13), indicando que los clusters no están bien definidos en el espacio de features disponible. Esto es coherente con el bajo desempeño en clasificación supervisada: los perfiles de empleados no son linealmente separables con las variables seleccionadas. Sin embargo, Davies-Bouldin decrece consistentemente hasta  $k=7$  (1.6058), sugiriendo que  $k=7$  ofrece la mejor separación relativa entre clusters. Se seleccionó  $k=7$  como configuración óptima.

### 5.2 DBSCAN

DBSCAN con parámetros por defecto identificó 1 único cluster con 0% de ruido. Esto indica que los datos son demasiado densos y uniformes para que DBSCAN detecte separaciones naturales con  $\epsilon$  por defecto. Se recomienda tuning de  $\epsilon$  mediante curva  $k$ -distance para exploración futura.

### 5.3 Clustering Aglomerativo

Agglomerative Clustering (Ward linkage) identificó 3 clusters sobre una muestra de 150 empleados para la visualización del dendrograma. La estructura jerárquica revela dos grandes ramas principales que se subdividen, consistente con la separación entre empleados activos y terminados detectada en el análisis supervisado.

### 5.4 PCA

El Análisis de Componentes Principales sobre las 6 variables numéricas determinó:

- 80% de varianza explicada: 5 componentes
- 90% de varianza explicada: 6 componentes

Dado que con 6 componentes se captura el 90% de la varianza y hay exactamente 6 features numéricas, esto indica baja redundancia entre variables: cada feature aporta información única al



modelo. La visualización 2D/3D de los componentes principales coloreados por cluster K-Means muestra superposición significativa, confirmando la baja separabilidad de los datos.

## 5.5 Gaussian Mixture Models (GMM)

Se evaluaron GMM para  $n=1$  a  $n=8$  componentes:

| n | BIC      | AIC      |
|---|----------|----------|
| 1 | 51283.54 | 51121.37 |
| 2 | 51025.79 | 50695.43 |
| 3 | 50702.27 | 50203.74 |
| 4 | 50552.64 | 49885.93 |
| 5 | 47433.74 | 46598.85 |
| 6 | 47303.73 | 46300.67 |
| 7 | 47493.32 | 46322.08 |
| 8 | 32203.04 | 30863.62 |

BIC y AIC decrecen hasta  $n=8$ , donde se observa una caída pronunciada (BIC: 47493  $\rightarrow$  32203). Esto sugiere que el modelo con 8 componentes gaussianos captura significativamente mejor la estructura de los datos, posiblemente correspondiendo a los 8 títulos de trabajo o tipos de unidad de negocio presentes en el dataset. Sin embargo, un número alto de componentes aumenta el riesgo de sobreajuste en el modelo de mezcla.

## 6. Conclusiones y Recomendaciones

---

### 6.1 Conclusiones Principales

- **Clasificación binaria:** El problema de predicción de fuga presenta desafíos significativos por el fuerte desbalanceo de clases (87%/13%). Gaussian Naïve Bayes emerge como campeón por su alto Recall (0.902), priorizando correctamente la detección de empleados en riesgo de fuga sobre la precisión.
- **Tuning:** La optimización de hiperparámetros generó una mejora del 41% en F1-Score (0.2676 → 0.3773), demostrando la importancia del tuning sistemático incluso en modelos simples.
- **Clasificación multiclase:** Logistic Regression supera a modelos más complejos en la tarea multiclase (F1=0.289), sugiriendo que la relación entre las features disponibles y el desempeño es predominantemente lineal.
- **Regresión:** El  $R^2$  negativo en regresión indica que Current Employee Rating no es predecible con las features actuales. Esto es una conclusión válida que orienta la recolección de nuevos datos.
- **Clustering:** Los bajos coeficientes Silhouette (0.13) en clustering confirman que los perfiles de empleados no forman grupos naturalmente separados en el espacio numérico, pero  $k=7$  ofrece la mejor segmentación relativa.

### 6.2 Recomendaciones Futuras

- Incorporar variables de rendimiento histórico (KPIs por trimestre, evaluaciones 360°) para mejorar la predicción de regresión y clasificación.
- Explorar CatBoost o LightGBM para manejo nativo de variables categóricas y potencialmente superar a XGBoost.
- Implementar SHAP values para explicabilidad del modelo campeón, requerimiento crítico en aplicaciones de RRHH.
- Tuning de DBSCAN mediante curva k-distance para explorar clustering basado en densidad de forma adecuada.
- Aplicar RandomizedSearchCV sobre Logistic Regression (campeón multiclase) para potencialmente superar el F1=0.289 actual.
- Considerar un enfoque de threshold optimization sobre Gaussian NB tuneado para balancear Precision-Recall según el costo de negocio de los falsos negativos.

## 7. Referencias

---

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

Rana, R. S. (2023). Synthetic Employee Records Dataset. Kaggle. Recuperado de <https://www.kaggle.com/datasets/ravindrasinghrana/employeeedataset>

Kedro Development Team. (2023). Kedro: A Python Framework for Reproducible, Maintainable and Modular Data Science Code (v0.19). QuantumBlack, AI by McKinsey.

Rousseeuw, P. J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

Davies, D. L., & Bouldin, D. W. (1979). A Cluster Separation Measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2), 224–227.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in Python* (2nd ed.). Springer.